# Лабораторная работа №1.
# Подбор закона распределения к реальным выборкам

## Цель работы

Научиться по эмпирическим данным:

- строить гистограммы и оценки плотности;
- оценивать параметры распределений;
- проверять гипотезы о виде распределения с помощью критерия $\chi^2$;
- выбирать закон распределения, наилучшим образом соответствующий выборке, допуская, что нескольким распределениям данные могут не противоречить.

## Исходные данные

Каждому студенту выдаётся набор из **пяти выборок** $X_1, \ldots, X_5$ разного объёма $N_i \in \{150, \ldots, 500\}$, сгенерированных из **неизвестных** распределений. Выборки генерируются самостоятельно с помощью скрипта $\mathrm{generate_samples.R}$ (с индивидуальным seed). Истинные законы распределения студенту не сообщаются.

## Задание

Для каждой выборки $X_j$, $j = 1, \ldots, 5$, выполнить следующее.

1. **Первичный анализ.**
   a) Импортировать данные. Определить объём выборки $N_j$.
   b) Построить гистограмму с разумным числом интервалов (например, по правилу Стёрджеса или Скотта).
   c) Построить ядерную оценку плотности (KDE) и эмпирическую функцию распределения (ECDF).
   d) Вычислить выборочные характеристики: среднее $\bar{x}$, медиану, выборочную дисперсию $s^2$, стандартное отклонение $s$, коэффициенты асимметрии и эксцесса, min/max, квартили.
   e) Сделать предварительный вывод: является ли выборка симметричной, есть ли тяжёлые хвосты, дискретна ли она, есть ли ограничения на носитель (например, $x \geq 0$).
2. **Формулировка конкурирующих гипотез.**
   a) На основании п. 1 выдвинуть **не менее трёх** гипотез о законе распределения из следующего списка:
      - равномерное $U[a, b]$;
      - нормальное $N(a, \sigma^2)$;
      - экспоненциальное $\mathrm{Exp}(\lambda)$;
      - $\chi^2(k)$;
      - Пуассона $\mathrm{Pois}(\lambda)$;
      - биномиальное $\mathrm{Bin}(n, p)$;
      - геометрическое $\mathrm{Geom}(p)$;
      - логнормальное;

- гамма-распределение;
- распределение Вейбулла.

b) Для каждой гипотезы указать, какие параметры неизвестны и подлежат оценке.

**3. Оценка параметров.**

a) Для всех предполагаемых распределений оценить параметры методом моментов и/или методом максимального правдоподобия (MLE).

b) Сравнить оценки, полученные разными методами, если это возможно.

**4. Проверка гипотез с помощью критерия $\chi^2$.**

a) Для каждой гипотезы сформировать интервалы группировки (или группы значений для дискретных распределений) так, чтобы ожидаемые частоты в каждой группе были $\geq 5$ (при необходимости объединять соседние интервалы). Это можно сделать с помощью функции "hist".

b) Вычислить статистику

$$\chi^2 = \sum_{i=1}^{m} \frac{(O_i - E_i)^2}{E_i},$$

где $O_i$ — наблюдаемые частоты, $E_i$ — ожидаемые частоты при оценённых параметрах.

c) Определить число степеней свободы $df = m - 1 - s$, где $s$ — число оценённых параметров.

d) Найти $p$-value и сделать вывод при уровне значимости $\alpha = 0.05$.

e) **Важно:** в пакете R можно реализовать встроенную функцию для критерия $\chi^2$.

f) **Важно:** если для одной и той же выборки несколько распределений не отвергаются, это нормально. Нужно не просто выбрать «единственное», а ранжировать гипотезы по $p$-value и по визуальному соответствию гистограммы и теоретической плотности.

**5. Сравнение гипотез и итоговый выбор.**

a) Свести результаты в таблицу: распределение, оценки параметров, $\chi^2$, $df$, $p$-value, вывод (не отвергается / отвергается).

b) Для каждой неотвергнутой гипотезы наложить теоретическую плотность (или вероятности) на гистограмму.

c) Построить график ECDF и теоретической функции распределения для наилучшей гипотезы.

d) Сделать итоговый вывод: какое распределение (или какие распределения) наилучшим образом описывают выборку; обосновать выбор, учитывая как формальные тесты, так и визуальный анализ и содержательный смысл.

## Требования к отчёту по ЛР №1

Отчёт должен содержать по каждой из пяти выборок:

- графики: гистограмма + KDE, ECDF, наложенные теоретические плотности;
- таблицу с оценками параметров и результатами $\chi^2$-теста;
- обоснованный вывод о наиболее подходящем распределении (возможно, с указанием нескольких неотвергнутых альтернатив).